CARACTERIZACIÓN DESCRIPTIVA DE REGISTROS DE PACIENTES CON INSUFICIENCIA CARDÍACA: TRANSFORMACIÓN, ENRIQUECIMIENTO Y RESPUESTAS DESCRIPTIVAS

Ingeniería de Software y Datos | Institución Universitaria Digital de Antioquia
Asignatura: Proyecto Integrador III – Analítica de Datos
Actividad: S30 – AE3 Proyecto integrador – Transformación y Enriquecimiento de Datos
Código: PREICA2602B020038
Docente: Andrés Felipe Callejas Jaramillo
Estudiante: Pablo Emilio Gómez Gómez
Bogotá D. C., Colombia
2 de noviembre de 2026

Repositorio público y reproducible: https://github.com/Emiliog3/EA2_HeartFailure_Pablo_Gomez/tree/main/AE3

1. Introducción y necesidad de información

La tercera entrega del Proyecto Integrador III transforma y enriquece el conjunto público mstz/heart_failure (configuración death, partición train) para responder una necesidad descriptiva planteada en EA2: caracterizar 299 registros de personas con insuficiencia cardíaca y contrastar las variables disponibles entre quienes registraron o no muerte durante el seguimiento. Se trabaja sobre las 13 columnas originales, se conserva la procedencia y se producen seis variables derivadas, cinco tablas de resultados y un conjunto preparado de 19 columnas (mstz, s. f.). La estrategia privilegia decisiones verificables y resultados reproducibles, sin atribuir causalidad ni emitir diagnósticos (Chicco & Jurman, 2020; Harbison & Simmons, 2024).

Pregunta central. ¿Cómo se caracterizan y qué diferencias descriptivas se observan en las variables demográficas, clínicas y de estilo de vida disponibles entre los registros con y sin muerte documentada durante el seguimiento?

2. Objetivos y alcance

Objetivo general. Transformar, enriquecer y analizar descriptivamente el conjunto seleccionado, manteniendo su integridad y generando evidencias reproducibles que respondan la pregunta formulada en EA2.

De manera específica se busca: (1) comprobar la calidad y los tipos de datos antes y después de transformar; (2) documentar seis variables derivadas y actualizar el diccionario; (3) responder cinco preguntas descriptivas con tablas contrastables; y (4) exportar automáticamente datos, resultados y resumen para su validación en GitHub Actions.

La unidad de análisis es cada uno de los 299 registros del conjunto original. Se utiliza el split completo, sin muestreo adicional. Los datos corresponden a registros históricos de una población clínica específica, no a pacientes de Bogotá ni a una muestra representativa de Colombia (UCI Machine Learning Repository, 2020).

3. Fuente y metodología de procesamiento

La fuente consultada es el dataset mstz/heart_failure publicado en Hugging Face, configuración death y split train; la procedencia clínica subyacente se documenta en UCI. Se conserva una copia original sin modificación y se ejecuta una secuencia trazable: carga → diagnóstico de calidad → normalización de tipos → enriquecimiento → análisis → exportación → pruebas automatizadas. La documentación explícita de procedencia, transformaciones y límites sigue las recomendaciones de transparencia de datos (Pushkarna et al., 2022).

Tabla 1. Síntesis de validación y transformación

Dimensión	Valor verificado
Registros originales y finales	299 → 299; no se eliminan filas
Columnas originales, transformadas y finales	13 → 13 → 19
Valores nulos y duplicados exactos	0 y 0 en la inspección original; 0 nulos en el resultado
Códigos binarios fuera de 0/1	0; indicadores normalizados a 0/1
Rangos estructurales e inconsistencias	Sin violaciones detectadas en los controles aplicados
Regla de valores extremos	IQR como alerta descriptiva; no se eliminan extremos

Decisiones de limpieza. No se imputaron valores porque no había faltantes y no se eliminaron registros porque no se detectaron duplicados exactos ni anomalías estructurales que lo justificaran. Se convirtió la codificación de cinco indicadores booleanos a enteros 0/1 y el desenlace a entero anulable, sin modificar mediciones clínicas ni unidades. La completitud no equivale a certificar validez clínica (Cook et al., 2025; Gehrmann & Beyan, 2024).

Se documentaron posibles valores extremos por IQR: CPK (29), fracción de eyección (2), plaquetas (21), creatinina sérica (29) y sodio sérico (4); edad y días de seguimiento no tuvieron extremos según esa regla. Un extremo estadístico no se consideró automáticamente un error, por lo que todos se conservaron.

4. Enriquecimiento: seis variables documentadas

Las seis columnas nuevas proceden exclusivamente de variables ya presentes en el dataset. Son etiquetas o agrupaciones para lectura y futuras visualizaciones; no añaden observaciones médicas ni constituyen categorías diagnósticas.

Tabla 2. Reglas, significado y utilidad de las variables derivadas

Variable incorporada	Regla aplicada	Finalidad descriptiva
estado_seguimiento	is_dead: 1 = Registró muerte; 0 = No registró muerte	Identificar con claridad los grupos de contraste.
grupo_edad	Menos de 50; 50–59; 60–69; 70–79; 80 o más	Comparar frecuencias por intervalos de edad.
condiciones_registradas	has_anaemia + has_diabetes + has_high_blood_pressure	Contar tres condiciones disponibles (0–3).
nivel_condiciones_registradas	Agrupa conteo en 0, 1 y 2 o 3 condiciones	Presentar grupos legibles y comparables.
sexo_registrado	is_male: 1 = Masculino; 0 = Femenino	Reemplazar códigos por etiquetas en tablas.
tabaquismo_registrado	is_smoker: 1 = Sí; 0 = No	Interpretar el indicador registrado sin ambigüedad.

5. Diccionario del DataFrame final

La Tabla 3 relaciona las 19 columnas, sus tipos y codificaciones. Se utiliza la clasificación del diccionario exportado por el notebook aprobado en GitHub Actions; los tipos se muestran como evidencia técnica de esa ejecución. Las unidades se contrastan con la documentación de la fuente (UCI Machine Learning Repository, 2020).

Tabla 3. Diccionario actualizado de las 19 variables

Variable (nombre exacto)	Tipo pandas	Significado / unidad
age	int64	Edad; años
has_anaemia	int8	Indicador de anemia; 0/1
creatinine_phosphokinase_concentration_in_blood	float64	CPK en sangre; mcg/L
has_diabetes	int8	Indicador de diabetes; 0/1
heart_ejection_fraction	float64	Fracción de eyección; %
has_high_blood_pressure	int8	Presión arterial alta registrada; 0/1
platelets_concentration_in_blood	float64	Plaquetas; kiloplaquetas/mL
serum_creatinine_concentration_in_blood	float64	Creatinina sérica; mg/dL
serum_sodium_concentration_in_blood	float64	Sodio sérico; mEq/L
is_male	int8	Sexo masculino codificado; 0/1
is_smoker	int8	Tabaquismo registrado; 0/1
days_in_study	int64	Seguimiento; días
is_dead	Int8	Muerte durante el seguimiento; 0/1
estado_seguimiento	category	Etiqueta descriptiva del desenlace
grupo_edad	category	Intervalo descriptivo de edad
condiciones_registradas	int8	Conteo de condiciones (0–3)
nivel_condiciones_registradas	category	Nivel agrupado de condiciones
sexo_registrado	category	Etiqueta del sexo registrado
tabaquismo_registrado	category	Etiqueta del indicador de tabaquismo

Nota. El CSV exportado AE3/resultados/diccionario_datos_ae3.csv contiene el diccionario completo y auditable. Los nombres técnicos se conservan para facilitar las comprobaciones en Jupyter.

6. Resultados y respuestas a las cinco preguntas

El análisis mantiene la pregunta central de EA2 y la operacionaliza en cinco preguntas (P1–P5), cada una respaldada por un archivo CSV reproducible. Las comparaciones se restringen a los registros observados y no se presentan como estimaciones de riesgo poblacional.

6.1. P1. ¿Cómo se distribuye el desenlace registrado?

Tabla 4. Distribución del desenlace registrado (n = 299)

Estado de seguimiento	Registros	Porcentaje
No registró muerte	203	67,89 %
Registró muerte	96	32,11 %

En 203 registros no se documentó muerte y en 96 sí se registró durante el seguimiento. Estas proporciones describen la composición del conjunto y no deben extrapolarse como tasa de mortalidad de otras poblaciones.

6.2. P2. ¿Qué diferencias presentan las siete variables cuantitativas?

La Tabla 5 conserva las siete variables solicitadas: edad, CPK, fracción de eyección, plaquetas, creatinina sérica, sodio sérico y días de seguimiento. Se muestran media, mediana y desviación estándar por estado; el CSV contiene además cuartiles, valores mínimo y máximo, y coeficiente de variación.

Tabla 5. Estadísticos de las siete variables cuantitativas por estado

Variable	Grupo	n	Media	Mediana	Desv. est.
Edad (años)	Sin muerte	203	58,76	60	10,64
	Con muerte	96	65,21	65	13,22
CPK (mcg/L)	Sin muerte	203	540,05	245	753,80
	Con muerte	96	670,20	259	1.316,58
Fracción de eyección (%)	Sin muerte	203	40,27	38	10,86
	Con muerte	96	33,47	30	12,53
Plaquetas	Sin muerte	203	266.657,49	263.000	97.531,20
	Con muerte	96	256.381,05	258.500	98.525,68
Creatinina sérica (mg/dL)	Sin muerte	203	1,19	1,0	0,65
	Con muerte	96	1,84	1,3	1,47
Sodio sérico (mEq/L)	Sin muerte	203	137,22	137	3,98
	Con muerte	96	135,38	135,5	5,00
Seguimiento (días)	Sin muerte	203	158,34	172	67,74
	Con muerte	96	70,89	44,5	62,38

En el grupo con muerte registrada se observan mayores medianas de edad (65 frente a 60 años) y creatinina sérica (1,3 frente a 1,0 mg/dL), y menor mediana de fracción de eyección (30 frente a 38 %). CPK presenta fuerte dispersión, por lo que conviene leerla junto con su mediana; las plaquetas muestran medias próximas en ambos grupos. El tiempo de seguimiento es sensiblemente menor entre quienes registraron muerte (mediana de 44,5 frente a 172 días), circunstancia que exige especial prudencia interpretativa.

6.3. P3. ¿Cómo cambian los indicadores binarios por grupo?

Tabla 6. Frecuencia y porcentaje de indicadores binarios

Indicador 1 = Sí	Sin muerte (n = 203)	Con muerte (n = 96)
Anemia	83 (40,89 %)	46 (47,92 %)
Diabetes	85 (41,87 %)	40 (41,67 %)
Presión arterial alta	66 (32,51 %)	39 (40,62 %)
Sexo masculino	132 (65,02 %)	62 (64,58 %)
Tabaquismo	66 (32,51 %)	30 (31,25 %)

Las proporciones de anemia y presión arterial alta son mayores entre los registros con muerte documentada; las de diabetes, sexo masculino y tabaquismo son semejantes entre grupos. Las diferencias corresponden a observaciones del dataset y no permiten deducir relaciones causales.

6.4. P4. ¿Cómo varía el desenlace por grupo de edad?

Tabla 7. Distribución del desenlace por grupos descriptivos de edad

Grupo de edad	Total	Muerte registrada	Sin muerte	% con muerte
< 50 años	47	11	36	23,40 %
50–59	82	20	62	24,39 %
60–69	93	27	66	29,03 %
70–79	52	20	32	38,46 %
80 o más	25	18	7	72,00 %

La proporción observada de muerte registrada pasa de 23,40 % en menores de 50 años a 72,00 % en registros de 80 años o más. Los rangos fueron definidos para describir el conjunto, no como puntos de corte clínicos ni estimaciones de riesgo individual.

6.5. P5. ¿Cómo varía el desenlace según condiciones registradas?

Tabla 8. Desenlace según el número de condiciones registradas

Condiciones registradas	Total	Muerte registrada	Sin muerte	% con muerte
0 condiciones	67	19	48	28,36 %
1 condición	122	35	87	28,69 %
2 o 3 condiciones	110	42	68	38,18 %

El porcentaje de muerte registrada es 28,36 % con ninguna de las tres condiciones, 28,69 % con una y 38,18 % con dos o tres. Este conteo integra únicamente anemia, diabetes y presión arterial alta; no debe considerarse un índice clínico de comorbilidad.

7. Reproducibilidad, límites y proyección

Ejecución y trazabilidad. El repositorio público conserva el notebook ejecutado, el código modular, la fuente original, el dataset preparado (299 × 19), cinco tablas CSV, el archivo de calidad, el diccionario y el resumen automático TXT. El workflow de GitHub Actions instala dependencias, ejecuta el notebook desde cero y valida las evidencias. Las ejecuciones de AE2 y AE3 en main finalizaron satisfactoriamente el 2 de noviembre de 2026.

Rutas principales. AE3/notebooks/PABLO_GOMEZ_AE3_TRANSFORMACION_ENRIQUECIMIENTO.ipynb; AE3/datos/heart_failure_preparado.csv; AE3/resultados/; AE3/documento/; .github/workflows/validacion_ae3.yml.

Limitaciones. La base reúne 299 registros históricos de un contexto clínico específico y no representa a Bogotá, Colombia ni a la población general. No se conocen variables omitidas, sesgos de selección ni la validez clínica de todas las mediciones. Los seguimientos difieren en duración; tampoco se aplicaron pruebas inferenciales, modelos predictivos ni ajustes por factores de confusión. Las agrupaciones derivadas facilitan lectura, pero no son categorías diagnósticas (UCI Machine Learning Repository, 2020; Gehrmann & Beyan, 2024).

Conclusión. AE3 responde la necesidad de EA2 mediante controles documentados, seis variables nuevas y cinco resultados descriptivos coherentes, conservando íntegros los 299 registros. La exportación reproducible permite reutilizar las métricas en la siguiente etapa del proyecto sin alterar la lógica analítica.

8. Referencias

Chicco, D., & Jurman, G. (2020). Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone. BMC Medical Informatics and Decision Making, 20, 16. https://doi.org/10.1186/s12911-020-1023-5

Cook, R. M., Dube, A., Asaduzzaman, M., Beales, T., Pearce, R., Blackwell, L., Whitehouse, C., Miller, J., Gough, M., Radford, M., Leary, A., & Jones, S. (2025). A data quality assurance process to improve the precision of analysis of routinely collected administrative data for the NHS (National Health Service) UK. Health Informatics Journal, 31(2). https://doi.org/10.1177/14604582251334338

Gehrmann, J., & Beyan, O. (2024). Data quality in medical real-world data: An oncological use case. Studies in Health Technology and Informatics, 316, 9–13. https://doi.org/10.3233/SHTI240332

Harbison, L., & Simmons, K. (2024). Fundamentals of descriptive statistics. Journal of Dental Hygiene, 98(5), 51–54. https://pubmed.ncbi.nlm.nih.gov/39406491/

mstz. (s. f.). heart_failure [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/mstz/heart_failure

Pushkarna, M., Zaldivar, A., & Kjartansson, O. (2022). Data cards: Purposeful and transparent dataset documentation for responsible AI. Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency, 1776–1826. https://doi.org/10.1145/3531146.3533231

UCI Machine Learning Repository. (2020). Heart Failure Clinical Records [Conjunto de datos]. https://doi.org/10.24432/C5Z89R