CARACTERIZACIÓN DESCRIPTIVA DE REGISTROS DE PACIENTES CON INSUFICIENCIA CARDÍACA: Ideación, diseño y documentación de una necesidad de analítica de datos

Ingeniería de Software y Datos | Institución Universitaria Digital de Antioquia
Asignatura: Proyecto Integrador III – Analítica de Datos
Actividad: S30 – EA2 Proyecto integrador – Ideación, Diseño y Documentación Necesidad
Código: PREICA2602B020038
Docente: Andrés Felipe Callejas Jaramillo
Estudiante: Pablo Emilio Gómez Gómez
Bogotá D. C., Colombia
25 de octubre de 2026

En línea en: https://github.com/Emiliog3/EA2_HeartFailure_Pablo_Gomez

1 Tabla de contenido

2 Introducción 3
3 Planteamiento de la necesidad 4
4 Justificación 5
5 Objetivos 6
5.1 Objetivo general 6
5.2 Objetivos específicos 6
6 Marco teórico inicial 7
6.1 Analítica descriptiva 7
6.2 DataFrame y reconocimiento estructural 7
6.3 Registros de insuficiencia cardíaca y variables disponibles 7
6.4 Reproducibilidad y trazabilidad 8
7 Metodología de la etapa 1 9
7.1 Selección y ficha del dataset 9
7.2 Unidad de análisis 10
7.3 Diccionario inicial de variables relevantes 10

7.4 Alcance 11
7.5 Limitaciones 11
7.6 Diseño inicial del análisis 12
8 Reconocimiento del dataset 12
9 Referencias 13

Índice de tablas

Tabla 1. Ficha técnica del dataset 8
Tabla 2. Diccionario inicial de variables 10
Tabla 3. Diseño inicial del análisis 11

CARACTERIZACIÓN DESCRIPTIVA DE REGISTROS DE PACIENTES CON INSUFICIENCIA CARDÍACA: Ideación, diseño y documentación de una necesidad de analítica de datos

2 Introducción

En esta primera etapa del Proyecto Integrador III, el trabajo comienza por reconocer qué información contienen los datos y qué necesidad puede abordarse con ellos, antes de decidir qué transformaciones, indicadores o representaciones gráficas serán pertinentes. Para ello se seleccionó el conjunto público mstz/heart_failure, alojado en Hugging Face, específicamente su configuración death y el split train, cuya versión disponible reúne 299 registros y 13 columnas sobre características demográficas, condiciones registradas, mediciones clínicas, tiempo de seguimiento y muerte durante ese periodo (mstz, s. f.). Esta elección permite desarrollar una propuesta de analítica descriptiva con información identificable, de tamaño manejable y vinculada a una pregunta que puede responderse con las variables realmente disponibles.

La selección también exige distinguir entre el lugar donde se consulta el dataset y la procedencia de sus registros, pues disponer de un archivo en una plataforma no equivale a conocer cómo se obtuvo la información original. La UCI Machine Learning Repository (2020) documenta que el Heart Failure Clinical Records Dataset reúne información de 299 pacientes con insuficiencia cardíaca y que no registra valores faltantes en las variables descritas; por su parte, Chicco y Jurman (2020) presentan el estudio asociado y sitúan la recopilación de los datos en Faisalabad, Pakistán, durante 2015. Esta trazabilidad resulta especialmente importante en un proyecto de datos en salud, donde las características de la fuente condicionan el alcance de cualquier lectura posterior.

Sobre esa base, el propósito del trabajo consiste en diseñar una caracterización de los registros y preparar comparaciones descriptivas entre quienes presentaron y quienes no presentaron el evento de muerte durante el seguimiento, sin formular diagnósticos individuales, predicciones ni explicaciones causales. Harbison y Simmons (2024) recuerdan que las estadísticas descriptivas permiten organizar las características

observadas, pero su interpretación depende de utilizar medidas apropiadas y de no atribuirles alcances que no tienen; por ello, las diferencias que se encuentren en etapas posteriores se comunicarán como diferencias dentro de este conjunto, no como efectos clínicos comprobados. La propuesta da continuidad a EA1: aquella actividad partió de 299 filas y 13 columnas, generó cinco transformaciones y terminó con 15 columnas, mientras que AE2 retoma deliberadamente las 13 variables de origen para documentar primero la necesidad y mantener la correspondencia con Hugging Face.

3 Planteamiento de la necesidad

Escenario y beneficiario. Se propone un escenario hipotético en el que un equipo universitario de Ingeniería de Software y Datos recibe registros históricos de pacientes con insuficiencia cardíaca y necesita comprender su estructura antes de elaborar un informe para discusión académica. El beneficiario sería ese equipo, que debe reconocer qué características pueden describirse, qué grupos aparecen en la información y cuáles son las restricciones del conjunto antes de utilizarlo como insumo de nuevas etapas. Esta manera de comenzar se relaciona con lo expuesto por Pushkarna et al. (2022), quienes destacan que documentar procedencia, uso previsto y limitaciones de los datasets ayuda a evitar interpretaciones desligadas del contexto en el que fueron construidos.

Necesidad de información. En ese escenario, se requiere establecer cómo se distribuyen la edad, el sexo registrado, los antecedentes o condiciones de anemia, diabetes, hipertensión y tabaquismo, así como las mediciones de fracción de eyección, creatina fosfoquinasa, plaquetas, creatinina sérica y sodio sérico; también interesa conocer el tiempo de seguimiento y preparar una comparación descriptiva entre los registros agrupados por el indicador de muerte. La necesidad no surge de un problema asistencial comprobado en una institución determinada, sino de una pregunta académica formulada a partir de la disponibilidad de estas variables. Como advierten Gehrmann y Beyan (2024) al estudiar la calidad de los datos médicos, reconocer la composición y las restricciones de una base resulta indispensable para juzgar qué usos posteriores son razonables, de manera que aquí no se asumirá representatividad poblacional ni se sostendrá que una variable produjo el desenlace.

Pregunta de análisis. ¿Cómo se caracterizan y qué diferencias descriptivas se observan en las variables demográficas, clínicas y de estilo de vida disponibles entre los pacientes que registraron y los que no registraron muerte durante el seguimiento del dataset mstz/heart_failure?

4 Justificación

La utilidad de esta propuesta comienza antes de generar resultados, porque una pregunta analítica bien formulada exige saber qué representa cada fila, qué contienen las columnas y qué clase de resumen puede construirse sin desbordar el alcance de los datos. Tandon et al. (2025) sitúan la analítica descriptiva como una forma de reconocer patrones y caracterizar información sanitaria observada, sin confundir esa primera lectura con un análisis de causas; de manera complementaria, Harbison y Simmons (2024) explican que la elección de frecuencias, porcentajes o medidas numéricas debe corresponder con el tipo de variable. En consecuencia, la justificación de este proyecto no depende de prometer resultados clínicos, sino de ofrecer una base organizada y verificable para conocer los registros.

Además de su pertinencia temática, el dataset es apropiado por su extensión y estructura, pues sus 299 filas pueden cargarse en un computador personal y sus 13 columnas incluyen tanto indicadores binarios como mediciones numéricas que facilitan distinguir posibles formas de descripción. El repositorio de Hugging Face muestra el split train y sus nombres de columnas, mientras que UCI Machine Learning Repository (2020) aporta definiciones y unidades para el conjunto subyacente, lo cual permite construir un diccionario sin asignar significados arbitrarios. No obstante, contar con cero valores nulos no equivale a haber comprobado toda la calidad del registro: Cook et al. (2025) muestran que la evaluación de información sanitaria requiere controles adicionales, una distinción que se mantendrá explícita en las limitaciones de esta primera etapa.

De este modo, el aporte esperado consiste en dejar trazada una ruta de análisis que otras personas puedan revisar y reproducir: las variables cualitativas se podrán resumir mediante conteos y proporciones, mientras que las cuantitativas admitirán medidas de tendencia central y dispersión, siempre que sus distribuciones se examinen antes de elegir el indicador más adecuado (Harbison & Simmons, 2024). Esas decisiones

prepararán las etapas siguientes y ayudarán a formular comparaciones dentro del conjunto, sin trasladar automáticamente sus resultados a Bogotá, a Colombia o a otras poblaciones, puesto que los registros no constituyen una muestra de dichos territorios. Así, la justificación conecta la necesidad académica con un uso responsable y técnicamente delimitado de la información.

5 Objetivos

5.1 Objetivo general

Caracterizar las variables demográficas, clínicas y de estilo de vida de los pacientes con insuficiencia cardíaca registrados en el dataset mstz/heart_failure, mediante técnicas de analítica descriptiva que permitan identificar sus principales características y comparar los registros según la ocurrencia de muerte durante el seguimiento, con el propósito de establecer una base de información organizada y reproducible para el desarrollo de las siguientes etapas del proyecto integrador.

5.2 Objetivos específicos

- Documentar la procedencia, estructura y condiciones de uso del dataset mstz/heart_failure, mediante la revisión de sus características técnicas, variables, tipos de datos y nivel de completitud, con el fin de establecer su pertinencia y las limitaciones para el desarrollo del proyecto.
- Identificar las características demográficas, clínicas y de estilo de vida disponibles en el conjunto de datos, mediante su reconocimiento en un DataFrame y la elaboración de un diccionario inicial de variables, para determinar la información que permitirá responder la pregunta de análisis.
- Diseñar un procedimiento de analítica descriptiva que contemple la organización, el resumen y la comparación de los registros según el indicador de muerte durante el seguimiento, definiendo las variables, las técnicas y los resultados esperados para orientar las siguientes etapas del proyecto.

6 Marco teórico inicial

6.1 Analítica descriptiva

En términos metodológicos, la analítica descriptiva permite organizar datos observados para identificar su composición, sus frecuencias y la forma en que se distribuyen las mediciones, utilizando recursos como porcentajes, promedios, medianas y medidas de dispersión según la naturaleza de cada variable. Harbison y Simmons (2024) explican que estas herramientas facilitan comprender un conjunto antes de plantear interpretaciones más complejas, mientras que Tandon et al. (2025) distinguen su uso en salud de aproximaciones orientadas a explicar relaciones o anticipar eventos. En este proyecto, esa distinción orienta las decisiones técnicas: la finalidad es caracterizar registros históricos y planear comparaciones internas, no elaborar un pronóstico de supervivencia ni establecer mecanismos clínicos.

6.2 DataFrame y reconocimiento estructural

Para desarrollar esa descripción se utiliza un DataFrame de Pandas, una estructura que permite presentar información tabular en filas y columnas y examinarla mediante operaciones reproducibles en Python. En la documentación de pandas (s. f.-a) se especifica que dtypes informa el tipo de dato de cada variable, mientras que isna permite identificar posiciones sin valor y, al combinarse con sum, contabilizar esos faltantes por columna (pandas, s. f.-b). Estas comprobaciones se complementan con shape, columns y la visualización inicial de registros, de manera que el notebook no se limita a descargar un archivo: deja evidencia de qué fue cargado y de cuáles características se tuvieron en cuenta para formular la pregunta. Esta revisión estructural constituye el punto de partida, no una certificación completa de calidad clínica, como recuerdan Cook et al. (2025) al examinar procedimientos de control en bases de salud.

6.3 Registros de insuficiencia cardíaca y variables disponibles

La insuficiencia cardíaca constituye el contexto clínico de los datos, aunque el proyecto se desarrolla desde la ingeniería de datos y no desde la atención a pacientes. En una revisión reciente sobre las recomendaciones europeas de esta condición, Tomasoni et al. (2024) destacan el lugar que ocupan la evaluación y el seguimiento clínico dentro del manejo de la enfermedad; esa referencia ayuda a comprender por qué

resulta relevante documentar variables como la fracción de eyección o la creatinina sérica, pero no convierte esta actividad en una evaluación médica. Para reconocer el significado concreto de las columnas se toma como fuente primaria la ficha de UCI Machine Learning Repository (2020), que registra, entre otras, la fracción de eyección en porcentaje, la creatina fosfoquinasa en mcg/L, las plaquetas en kiloplaquetas/mL, la creatinina sérica en mg/dL, el sodio sérico en mEq/L y el tiempo de seguimiento en días.

Aunque el estudio de Chicco y Jurman (2020) examinó el mismo conjunto mediante técnicas predictivas, el presente avance no reproduce ese diseño ni intenta derivar factores pronósticos a partir de comparaciones simples. El indicador is_dead solo se utilizará para distinguir los registros según si ocurrió o no el evento durante el tiempo observado, y las demás columnas se considerarán características documentadas de los pacientes. Precisamente porque la duración del seguimiento puede variar entre registros, las diferencias descriptivas exigirán una interpretación prudente; los resultados posteriores no demostrarán por sí solos riesgo causal, eficacia terapéutica ni desenlaces extrapolables a otros escenarios.

6.4 Reproducibilidad y trazabilidad

La reproducibilidad implica que un tercero pueda identificar sin ambigüedades la fuente, reconstruir la carga, observar el mismo DataFrame y comprobar el contenido del resumen producido. Lhoest et al. (2021) describen la biblioteca Datasets como una herramienta que facilita acceder y procesar conjuntos de datos mediante procedimientos compartibles; sin embargo, esa capacidad técnica debe acompañarse de una documentación que explique la selección realizada. En ese sentido, Pushkarna et al. (2022) insisten en el valor de registrar procedencia, propósito y restricciones de uso, razón por la cual aquí se conserva el identificador mstz/heart_failure, la configuración death, el split train y la consulta realizada el 25 de octubre de 2026, tanto en el documento como en el notebook y en el archivo .txt. Esta consistencia permite continuar el proyecto sin confundir el conjunto original de AE2 con la versión transformada de EA1.

7 Metodología de la etapa 1

La etapa se desarrolla mediante un enfoque cuantitativo y descriptivo, con una secuencia que comienza en la identificación de la fuente, continúa con la lectura de su ficha y termina con la carga del split seleccionado y el reconocimiento de su estructura en Jupyter. De acuerdo con Pushkarna et al. (2022), el registro de procedencia y condiciones de uso forma parte de una documentación responsable; por ello, antes de analizar valores se identifican la unidad de análisis, las variables, las dimensiones y los datos faltantes. Después se formula una necesidad coherente con esa información y se define qué comparaciones podrían abordarse más adelante. No se aplican todavía pruebas inferenciales, transformaciones de fondo ni modelos de aprendizaje automático, porque esos procedimientos exceden los entregables de AE2.

7.1 Selección y ficha del dataset

Elemento	Descripción
Nombre visible	Heart failure
Identificador Hugging Face	mstz/heart_failure
Configuración	death
Split	train
Fecha de consulta	25 de octubre de 2026
Registros utilizados	299; se utiliza el split completo, no una muestra
Columnas del DataFrame	13
Formato reportado	CSV / dataset tabular
Procedencia documentada	Repositorio de Hugging Face; conjunto subyacente Heart Failure Clinical Records de UCI
Licencia/condiciones	Hugging Face muestra la etiqueta “cc”. UCI identifica el conjunto subyacente con licencia CC BY 4.0. Se registra la información de ambas fuentes sin inferir una variante adicional para la etiqueta del repositorio.
Datos sintéticos	No. Las fuentes los describen como registros clínicos históricos de pacientes.
Enlace	https://huggingface.co/datasets/mstz/heart_failure

Tabla 1. Ficha técnica del dataset.

La elección de esta fuente responde a criterios prácticos y metodológicos: el tamaño de 299 registros permite ejecutar el notebook con recursos informáticos corrientes, la presentación tabular facilita inspeccionar las variables y el split completo evita introducir una muestra adicional cuya selección deba justificarse. Al mismo tiempo, la documentación de UCI Machine Learning Repository (2020) permite contrastar los nombres que aparecen en Hugging Face con los significados originales, mientras que la perspectiva de Pushkarna et al. (2022) ayuda a reconocer por qué la ficha del dataset no debe reducirse a un enlace de descarga. Se trabaja con la totalidad del split disponible,

pero ello no implica que el conjunto represente a una población distinta de aquella de la que proceden los registros.

7.2 Unidad de análisis

La unidad de análisis es cada registro individual de paciente incluido en el dataset original, de manera que cada fila corresponde a una persona con insuficiencia cardíaca observada durante un periodo de seguimiento que se expresa en días. Esta precisión proviene de la descripción publicada por UCI Machine Learning Repository (2020) y es indispensable para evitar confundir los 299 registros con consultas repetidas, hospitalizaciones o series temporales individuales. A partir de esa definición, las comparaciones propuestas se organizarán entre grupos de registros, sin suponer que todas las personas tuvieron idéntico tiempo de seguimiento.

7.3 Diccionario inicial de variables relevantes

Variable	Significado	Tipo en DataFrame	Unidad
age	Edad del paciente	int64	años
has_anaemia	Indica si se registró anemia	bool	No aplica
creatinine_phosphokinase_ concentration_in_blood	Concentración de creatina fosfoquinasa (CPK) en sangre	float64	mcg/L
has_diabetes	Indica si se registró diabetes	bool	No aplica
heart_ejection_fraction	Fracción de eyección cardíaca	float64	%
has_high_blood_pressure	Indica si se registró hipertensión arterial	bool	No aplica
platelets_concentration_ in_blood	Concentración de plaquetas en sangre	float64	kiloplaquetas/mL
serum_creatinine_ concentration_in_blood	Concentración de creatinina sérica	float64	mg/dL
serum_sodium_ concentration_in_blood	Concentración de sodio sérico	float64	mEq/L
is_male	Indicador de sexo masculino en la versión de Hugging Face	bool	No aplica
is_smoker	Indica si la persona registra tabaquismo	bool	No aplica
days_in_study	Periodo de seguimiento	int64	días
is_dead	Indicador de muerte durante el periodo de seguimiento	int64 (0/1)	No aplica

Tabla 2. Diccionario inicial de variables.

Nota metodológica: El diccionario conserva los nombres exactos que se observan en la versión de Hugging Face, mientras que el significado de los atributos y sus unidades se contrasta con la ficha del conjunto clínico original publicada por UCI Machine Learning Repository (2020). Por esta razón, expresiones como is_male se mantienen tal como aparecen en el DataFrame, aunque para la explicación en español se utilice una denominación más comprensible. Esta decisión no es solo de presentación: como proponen Pushkarna et al. (2022), documentar con claridad las características y

transformaciones de una fuente ayuda a conservar su trazabilidad y reduce el riesgo de atribuir a una columna un sentido que los datos no respaldan.

7.4 Alcance

El alcance se circunscribe a los 299 registros y las 13 variables originales del split train de la configuración death, sin realizar muestreos adicionales ni construir todavía nuevas columnas para el análisis. En etapas posteriores se prevé describir frecuencias y proporciones de los indicadores categóricos y presentar medidas numéricas adecuadas a la distribución de las variables clínicas, siguiendo la distinción metodológica expuesta por Harbison y Simmons (2024). El indicador is_dead permitirá organizar comparaciones dentro del conjunto, pero no será utilizado para emitir juicios diagnósticos, demostrar causas ni generalizar resultados a pacientes de Bogotá, Colombia u otros territorios.

7.5 Limitaciones

- El conjunto es pequeño y corresponde a una población clínica específica; no debe asumirse representatividad de Bogotá, Colombia ni de todas las personas con insuficiencia cardíaca.
- Los datos son observacionales e históricos. Una asociación o diferencia descriptiva no demuestra causalidad.
- La variable days_in_study representa tiempo de seguimiento; comparar resultados sin considerar esta característica puede producir interpretaciones simplificadas.
- La ficha de Hugging Face resume la procedencia como un dataset proveniente de Kaggle, mientras que la documentación UCI y el artículo asociado permiten rastrear el conjunto clínico original. Esta trazabilidad se declara para evitar presentar una única plataforma como fuente primaria de los datos.
- Esta etapa no evalúa calidad clínica de las mediciones, sesgos de selección ni validez externa. Tampoco formula recomendaciones médicas.

7.6 Diseño inicial del análisis

Componente	Variables o acción	Relación con la pregunta
Reconocimiento	shape, columns, dtypes, isna().sum()	Confirma la estructura real antes de interpretar.
Caracterización demográfica	age, is_male	Describe composición básica del conjunto.
Condiciones registradas	has_anaemia, has_diabetes, has_high_blood_pressure, is_smoker	Permite comparar frecuencias y proporciones.
Variables clínicas/laboratorio	heart_ejection_fraction; creatinine_phosphokinase_concentration_in_blood; platelets_concentration_in_blood; serum_creatinine_concentration_in_blood; serum_sodium_concentration_in_blood	Permite resumir tendencia, dispersión y diferencias descriptivas.
Seguimiento y agrupación	days_in_study, is_dead	Ubica el periodo observado y forma los grupos de comparación.
Comunicación posterior	Tablas y visualizaciones descriptivas en las siguientes etapas	Responderá la pregunta sin introducir predicción o causalidad.

Tabla 3. Diseño inicial del análisis.

El diseño conserva una correspondencia verificable entre lo que se necesita conocer, la pregunta formulada, las variables existentes y los productos de cada etapa. En AE2 únicamente se ejecutará la obtención de datos, el reconocimiento básico y la generación automática de un resumen textual; las frecuencias, los indicadores de posición o dispersión y las visualizaciones detalladas se abordarán cuando corresponda dentro del proyecto. Esta organización evita anticipar hallazgos y responde al criterio de Harbison y Simmons (2024) de seleccionar las herramientas descriptivas según la naturaleza de los datos, de modo que el desarrollo técnico posterior siga respondiendo a la necesidad inicial.

8 Reconocimiento del dataset

El notebook PABLO_GOMEZ_EA2_RECONOCIMIENTO_DATASET.ipynb obtiene mstz/heart_failure desde Hugging Face, con la configuración death y el split train, y carga los 299 registros y las 13 columnas originales en un DataFrame de Pandas. La revisión presenta los primeros casos, las dimensiones y los tipos de las variables, cuyo significado se detalla en la Tabla 2. Lhoest et al. (2021) destacan la utilidad de los procedimientos reproducibles para acceder a conjuntos de datos, por lo que se conserva también el vínculo con la Actividad1 https://github.com/Emiliog3/EA1_HeartFailure_Pablo_Gomez En esta etapa se describen las 13 columnas fuente, no las 15 de la versión transformada de EA1.

La comprobación con df.isna().sum() permite contar los valores ausentes por columna y muestra cero faltantes en los 299 registros, en consonancia con la ficha de UCI Machine Learning Repository (2020). La documentación de pandas (s. f.-b) señala que isna identifica esas ausencias; sin embargo, la completitud observada no demuestra por sí sola que las mediciones sean clínicamente correctas. Cook et al. (2025) indican que la calidad de los datos sanitarios requiere verificaciones adicionales, que no se presentarán como realizadas en esta etapa.

En relación con la necesidad, age e is_male respaldan la caracterización demográfica; las columnas binarias describen condiciones registradas y tabaquismo; las variables clínicas permiten comparar mediciones; days_in_study representa el tiempo de seguimiento; e is_dead organiza los registros según el evento de muerte. Como explican Harbison y Simmons (2024), la interpretación de estas descripciones debe corresponder con la naturaleza de las variables y no extenderse a inferencias ajenas al conjunto. Por ello, la pregunta puede abordarse sin añadir atributos que el dataset no contiene.

El código se documenta de manera pedagógica: antes de cada instrucción relevante se incluyen dos comentarios separados, uno que explica cómo leer la línea y otro que indica para qué sirve. Esta decisión responde a la necesidad de mantener el ejercicio comprensible y verificable para un estudiante que está fortaleciendo sus competencias de programación, sin alterar la funcionalidad del notebook.

Finalmente, el notebook crea la carpeta resultados si hace falta y regenera resumen_dataframe.txt en UTF-8 cada vez que se ejecuta; ese archivo utiliza el mismo DataFrame mostrado en Jupyter e incluye el identificador, la configuración, el split, las dimensiones, los tipos y los nulos de cada variable. Su contenido también se presenta en pantalla, como evidencia de una salida reproducible. La documentación transparente que proponen Pushkarna et al. (2022) permite explicar por qué estas comprobaciones ayudan a verificar la coherencia entre el Word, el notebook y el resumen generado.

9 Referencias

Chicco, D., & Jurman, G. (2020). Machine learning can predict survival of patients with heart failure from serum creatinine and ejection fraction alone. *BMC Medical Informatics and Decision Making, 20*, Article 16. https://doi.org/10.1186/s12911-020-1023-5

Cook, R. M., Dube, A., Asaduzzaman, M., Beales, T., Pearce, R., Blackwell, L., Whitehouse, C., Miller, J., Gough, M., Radford, M., Leary, A., & Jones, S. (2025). A data quality assurance process to improve the precision of analysis of routinely collected administrative data for the NHS (National Health Service) UK. *Health Informatics Journal, 31*(2). https://doi.org/10.1177/14604582251334338

Gehrmann, J., & Beyan, O. (2024). Data quality in medical real-world data: An oncological use case. *Studies in Health Technology and Informatics, 316*, 9–13. https://doi.org/10.3233/SHTI240332

Harbison, L., & Simmons, K. (2024). Fundamentals of descriptive statistics. *Journal of Dental Hygiene, 98*(5), 51–54. https://pubmed.ncbi.nlm.nih.gov/39406491/

Hugging Face. (s. f.). *Load*. Hugging Face Datasets documentation. https://huggingface.co/docs/datasets/en/loading

Lhoest, Q., Villanova del Moral, A., Jernite, Y., Thakur, A., von Platen, P., Patil, S., Chaumond, J., Drame, M., Plu, J., Tunstall, L., Davison, J., Šaško, M., Chhablani, G., Malik, B., Brandeis, S., Le Scao, T., Sanh, V., Xu, C., Patry, N., ... Wolf, T. (2021). Datasets: A community library for natural language processing. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (pp. 175–184). Association for Computational Linguistics. https://doi.org/10.18653/v1/2021.emnlp-demo.21

mstz. (s. f.). *heart_failure* [Conjunto de datos]. Hugging Face. Recuperado el 25 de octubre de 2026, de https://huggingface.co/datasets/mstz/heart_failure

pandas. (s. f.-a). *pandas.DataFrame.dtypes*. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.dtypes.html

pandas. (s. f.-b). *pandas.DataFrame.isna*. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.isna.html

Pushkarna, M., Zaldivar, A., & Kjartansson, O. (2022). Data cards: Purposeful and transparent dataset documentation for responsible AI. In *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency* (pp. 1776–1826). ACM. https://doi.org/10.1145/3531146.3533231

Tandon, R., Harnden, A., & Brannan, G. D. (2025). Healthcare analytics. In *StatPearls*. StatPearls Publishing. https://www.ncbi.nlm.nih.gov/books/NBK614158/

Tomasoni, D., Cannatà, A., Adamo, M., & Metra, M. (2024). 2023 focused update of the 2021 ESC heart failure guidelines: Key messages for clinical practice. *European Journal of Clinical Investigation, 54*(4), e14163. https://doi.org/10.1111/eci.14163

UCI Machine Learning Repository. (2020). *Heart Failure Clinical Records* [Conjunto de datos]. https://doi.org/10.24432/C5Z89R